Raport

Jakub Kosterna, Marcin Łukaszyk, Mikołaj Malec

15/04/2020

1. Ogólnie

German credit data to bardzo ładny zbiór danych pod naukę uczenia maszynowego. Jest on względnie nieduży, gdyż zawiera 1000-czną próbkę osób ubiegających się o kredyt, jednak jest przy tym wydaje się reprezentatywny (dane zdają się dobrze odzwierciedlać populację) i zawiera dużo informacji na temat każdego klienta.

W ciągu ostatnich tygodni pierwszorzędnie dobrze zapoznaliśmy się z daną ramką danych, następnie przygotowaliśmy ją pod odpalania algorytmów machine learning, żeby na końcu wybrać ten jeden fajny model i go przetestować.

2. Czyszczenie

Pierwotna wersja data frame nie była najweselsza na świecie - zamiast ludzkich liczb czy jasnych wartości typu faktor, mieliśmy do czynienia z chaosem w postaci **dziwnych oznaczeń** takich jak widać na załączonym obrazku:

checking_account_status	duration	credit_history	purpose	credit_amount	savings	present_employment	installment_rate	personal	other_debtors	present_residence	property	age
A12	30	A34	A40	4249	A61	A71	4	A94	A101	2	A123	28
A11	18	A32	A42	1131	A61	A71	4	A92	A101	2	A123	33
A12	24	A32	A43	1967	A61	A75	4	A92	A101	4	A123	20
A11	12	A32	A42	1657	A61	A73	2	A93	A101	2	A121	27
A11	18	A32	A43	1882	A61	A73	4	A92	A101	4	A123	25
A14	9	A32	A49	1449	A61	A74	3	A92	A101	2	A123	27
A14	9	A32	A42	1313	A61	A75	1	A93	A101	4	A123	20
A12	42	A34	A49	5954	A61	A74	2	A92	A101	1	A121	41
A14	30	A32	A43	1867	A65	A75	4	A93	A101	4	A123	58
A12	12	A32	A40	1223	A61	A75	1	A91	A101	1	A121	46

Z pomocą przyszła **dokumentacja**, która rozwiała wszelkie możliwości. W celu dalszej pracy z naszymi danymi, podmieniliśmy skrótowe identyfikatory na ciągi znaków przyjazne użytkownikowi.

2. Czyszczenie danych

W celu ludzkiego przedstawienia danych zmodyfikujemy je tak, żeby wszystko stało się jasne.

```
# przeksztalcanie na dane numeryczne i z faktorami
levels(data[,1]) <- c("low", "fair", "high", "not_have") #DM low<0<fair<200<high
levels(data[,3]) <- c("all_paid", "all_paid_here", "paid_till_now", "delay", "critical")
levels(data[,4]) <- c("new_car", "used_car", "furniture/equipment", "radio/television", "domestic", "repairs", "education",
"retraining", "business", "other") #note: 0 for vacation
levels(data[,6]) <- c("low","normal","high","very_high","not_have/unknown") #DM low<100<normal<500<high<1000<very_high
levels(data[,7]) <- c("unemployed", "less_than_year", "1-3_years", "4-6_yeras","7+_years")
levels(data[,9]) <- c("male_d/s", "female_d/s/m", "male_single", "male_m/w") #d = divorsed, s = seperated, m = married, w =
widowed ,#note: 0 female single
levels(data[,10]) <- c("none", "co-applicant", "guarantor")
levels(data[,12]) <- c("real_estate", "building_savings", "car", "not_have/unknown")
levels(data[,14]) <- c("bank", "stores", "none")
levels(data[,15]) <- c("rent", "own", "for_free")
levels(data[,17]) <- c("unskilled_non_resident", "unskilled_resident", "skilled_eployee", "highly_qualified_employee*") # al
so management, self-employed, officer
levels(data[,19]) <- c("no", "yes")
levels(data[,20]) <- c("yes", "no")
data[,21] <- as.factor(as.character(data[,21]))
levels(data[,21]) <- c("Good", "Bad")
```

Jak teraz wygląda nasze losowe 20 wierszy?

Końcowy efekt zaprezentował się następująco:

checking_account_status	duration	credit_history	purpose	credit_amount	savings	present_employment	installment_rate	personal	other_debtors	present_residence	
low	15	paid_till_now	new_car	3959	low	1-3_years	3	female_d/s/m	none	2	I
fair	15	paid_till_now	new_car	2631	normal	1-3_years	2	female_d/s/m	none	4	(
low	18	critical	education	1190	low	unemployed	2	female_d/s/m	none	4	I
fair	18	delay	radio/television	4297	low	7+_years	4	male_d/s	none	3	I
not_have	24	paid_till_now	domestic	1311	normal	4-6_yeras	4	male_m/w	none	3	I
high	15	paid_till_now	retraining	1905	low	7+_years	4	male_single	none	4	(
fair	10	all_paid_here	domestic	1048	low	1-3_years	4	male_single	none	4	I
fair	15	paid_till_now	education	1308	low	7+_years	4	male_single	none	4	(
fair	27	critical	domestic	2520	high	1-3_years	4	male_single	none	2	I
not_have	24	critical	radio/television	1585	low	4-6_yeras	4	male_single	none	3	I
low	24	critical	domestic	1231	very_high	7+_years	4	female_d/s/m	none	4	I
fair	6	paid_till_now	education	454	low	less_than_year	3	male_m/w	none	1	I

Wielkim szczęściem okazał się za to fakt, że nasza ramka danych **nie zawierała braków ani niepokojących outlierów**.

3. Eksploracja

. . . dla tak przyjemnych i życiowych danych była czystą przyjemnością.

Bardzo pomocny okazało się narzędzie **DataExplorer**, które pokazało wiele ciekawych zależności w tabeli automatycznie.

Elegancki ogląd naszych danych otrzymaliśmy dzięki zaoferowanemu przez funkcję drzewko typów.

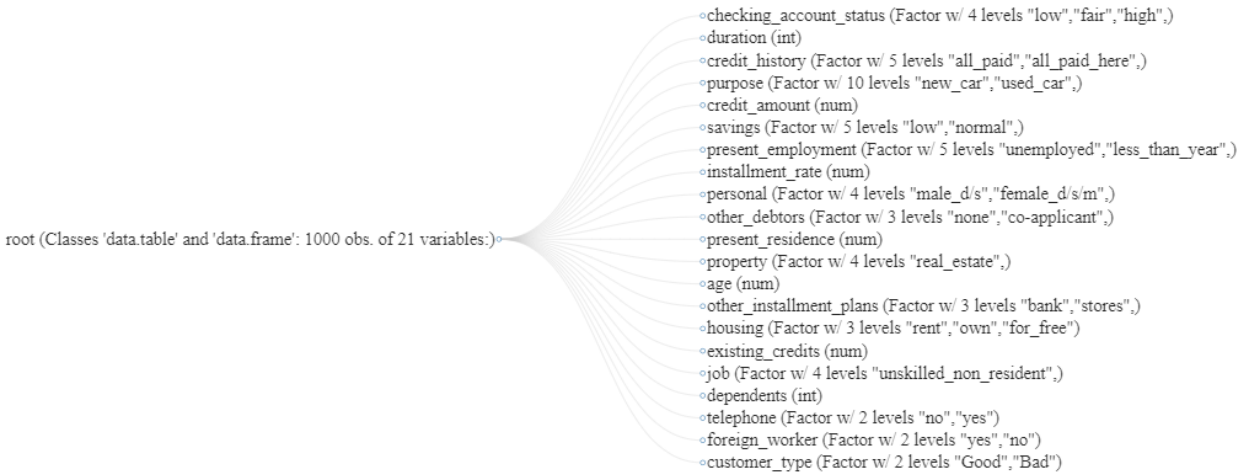

Wykresy kolumnowe gęstości występowania danych utwierdziły nas w przekonaniu, że z naszą ramką danych wszystko w porządalu.

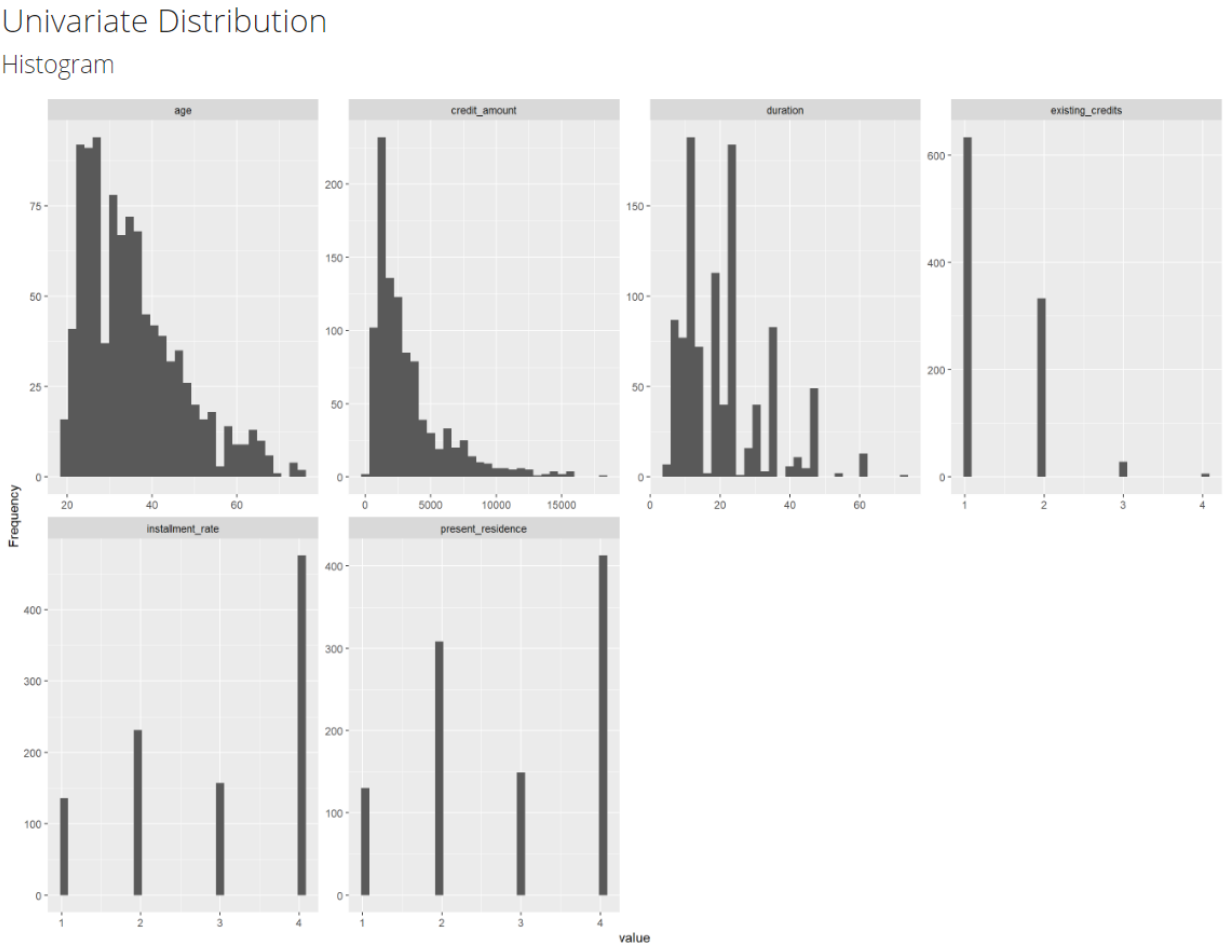

Ładny ogląd balansu wartości dały nam **barcharty zmiennych numerycznych**.

Bar Chart (by frequency)

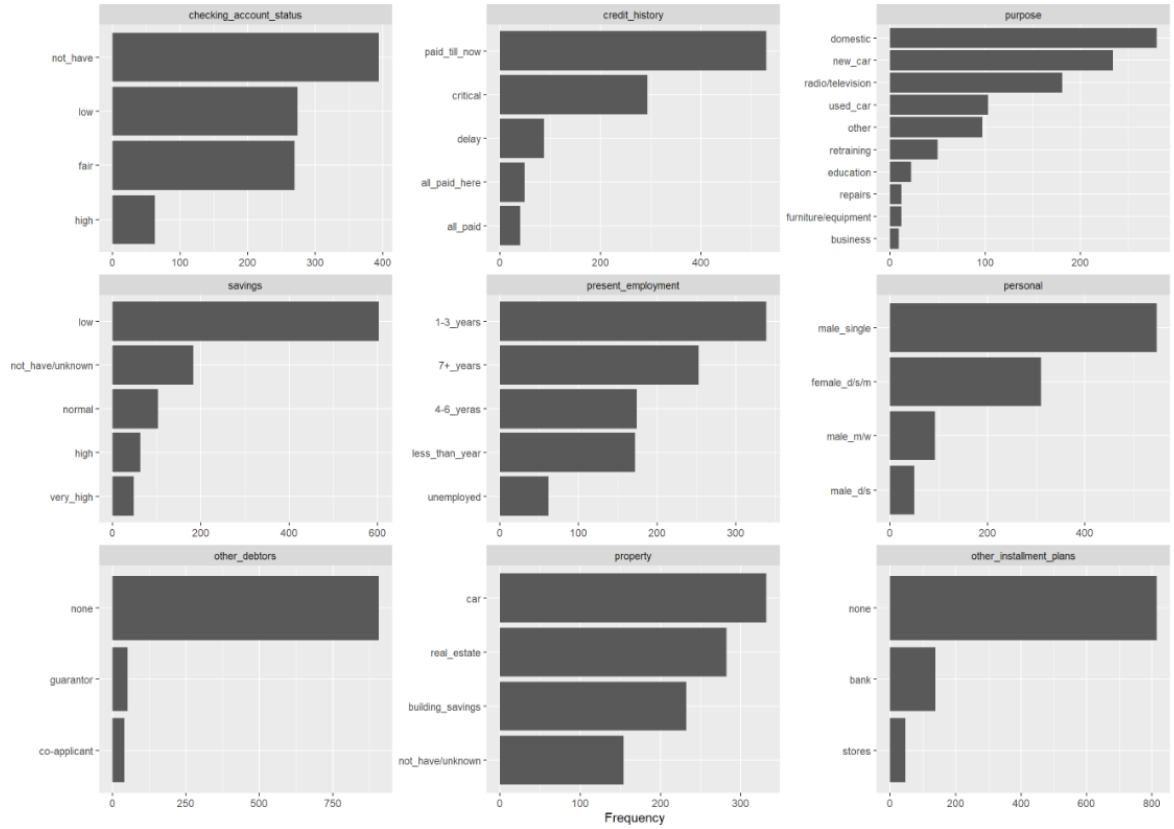

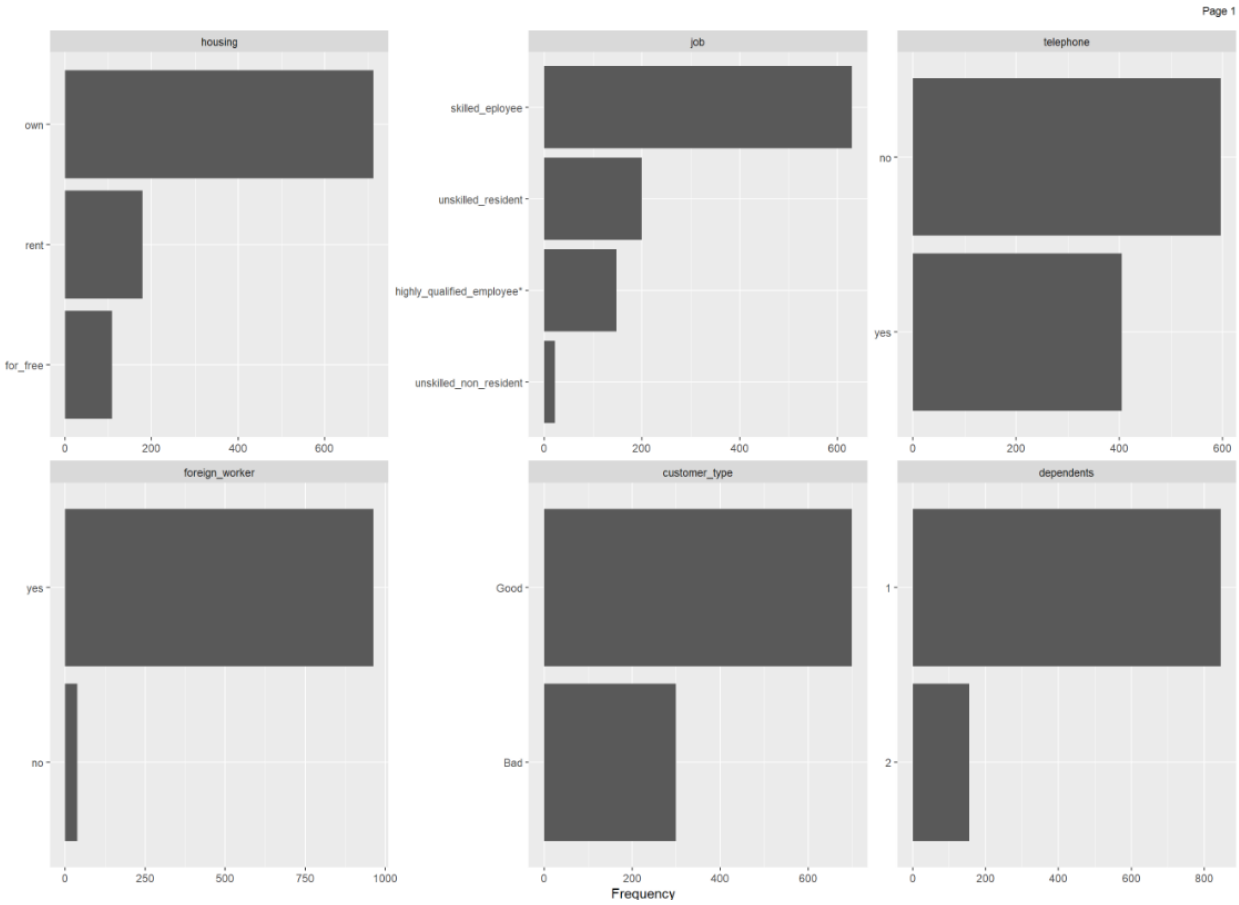

Bardzo przydatna okazała się także wizualizacja **QQplot** - dzięki niej dostaliśmy przystępny obraz wartości liczbowych w naszej dataframe oraz ich rozkład.

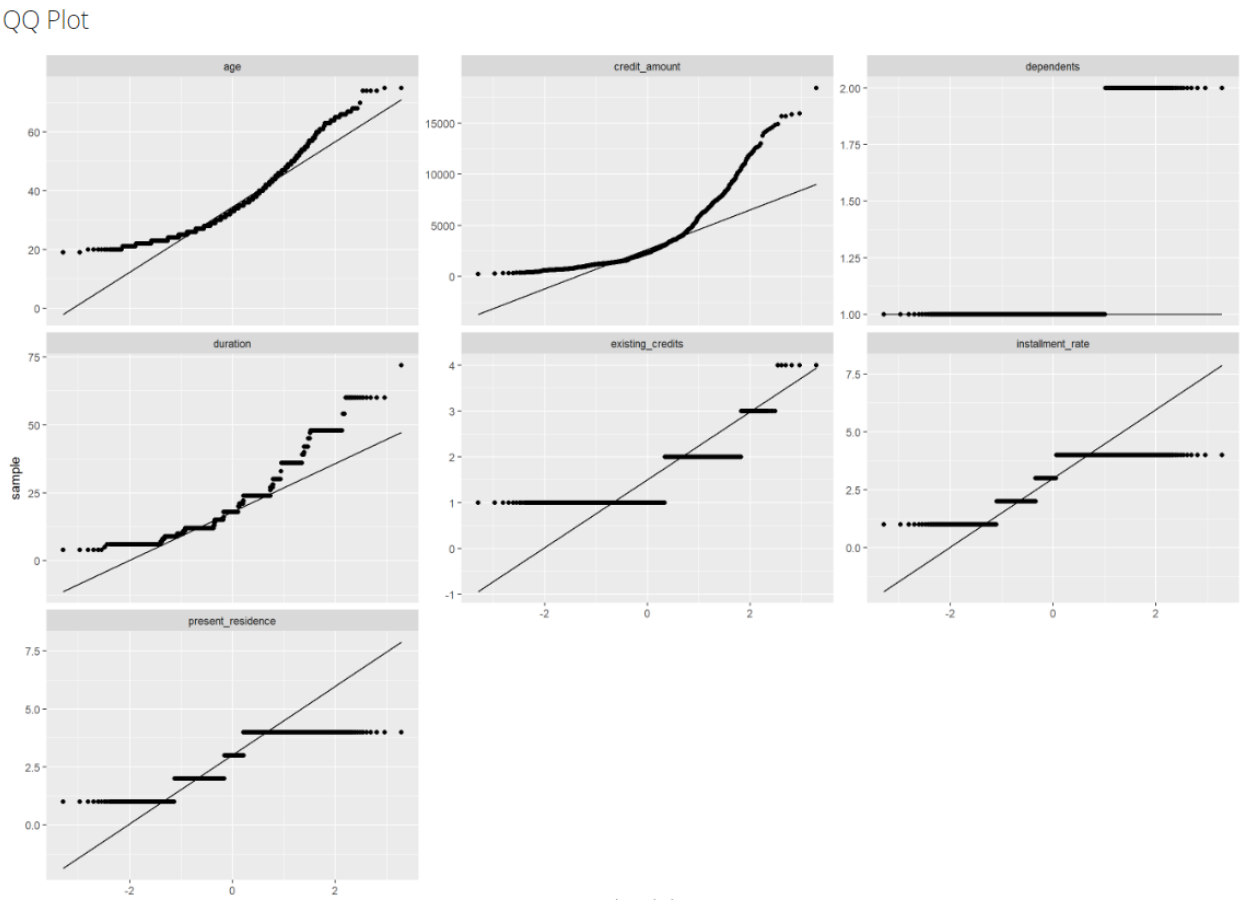

Także i **macierz korelacji** tym bardziej zbliżyła nas do pełnego pojęcia pełnego *german credit data* i wiele wartości pokryło się z naszą intuicją.

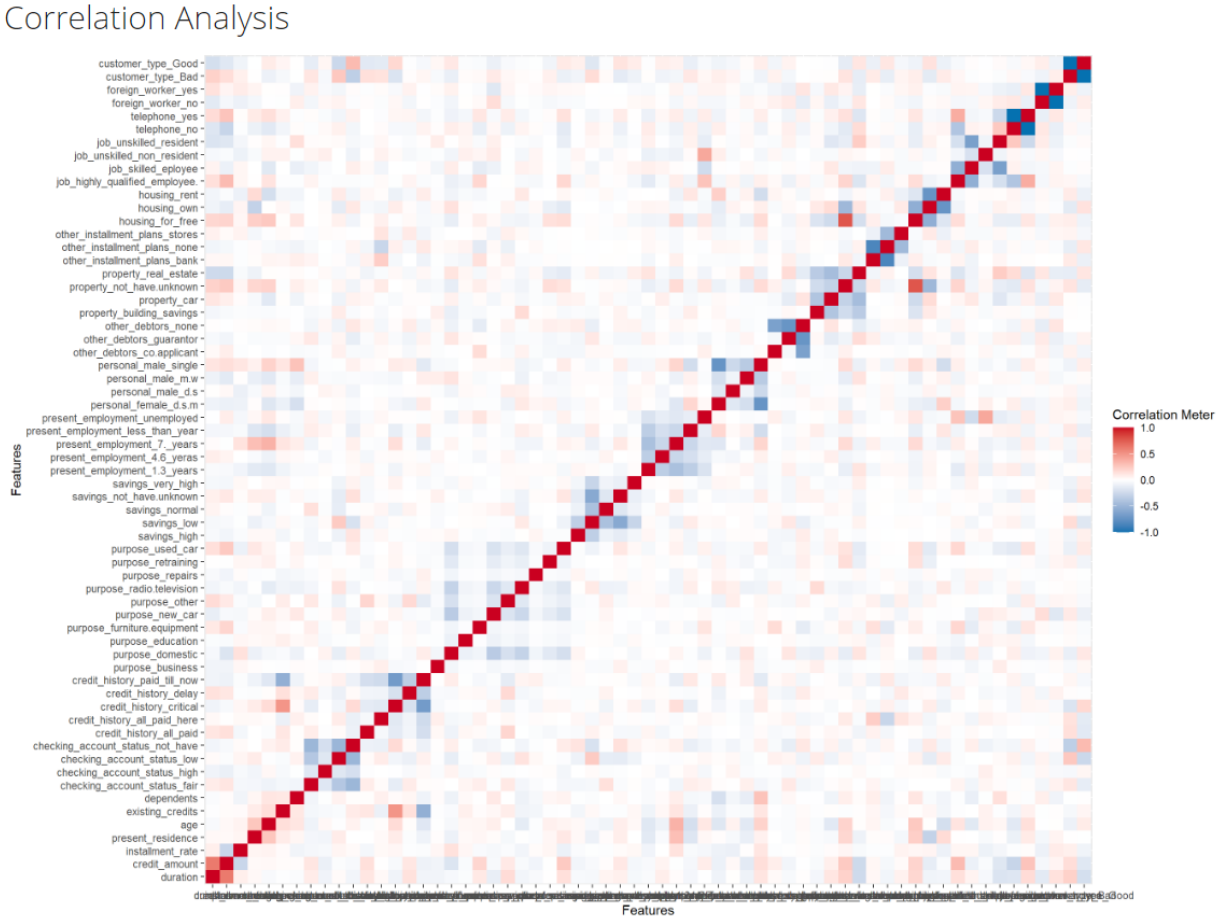

Na koniez przyjrzeliśmy się jeszcze **wykresowi analizy głównych składowych**.

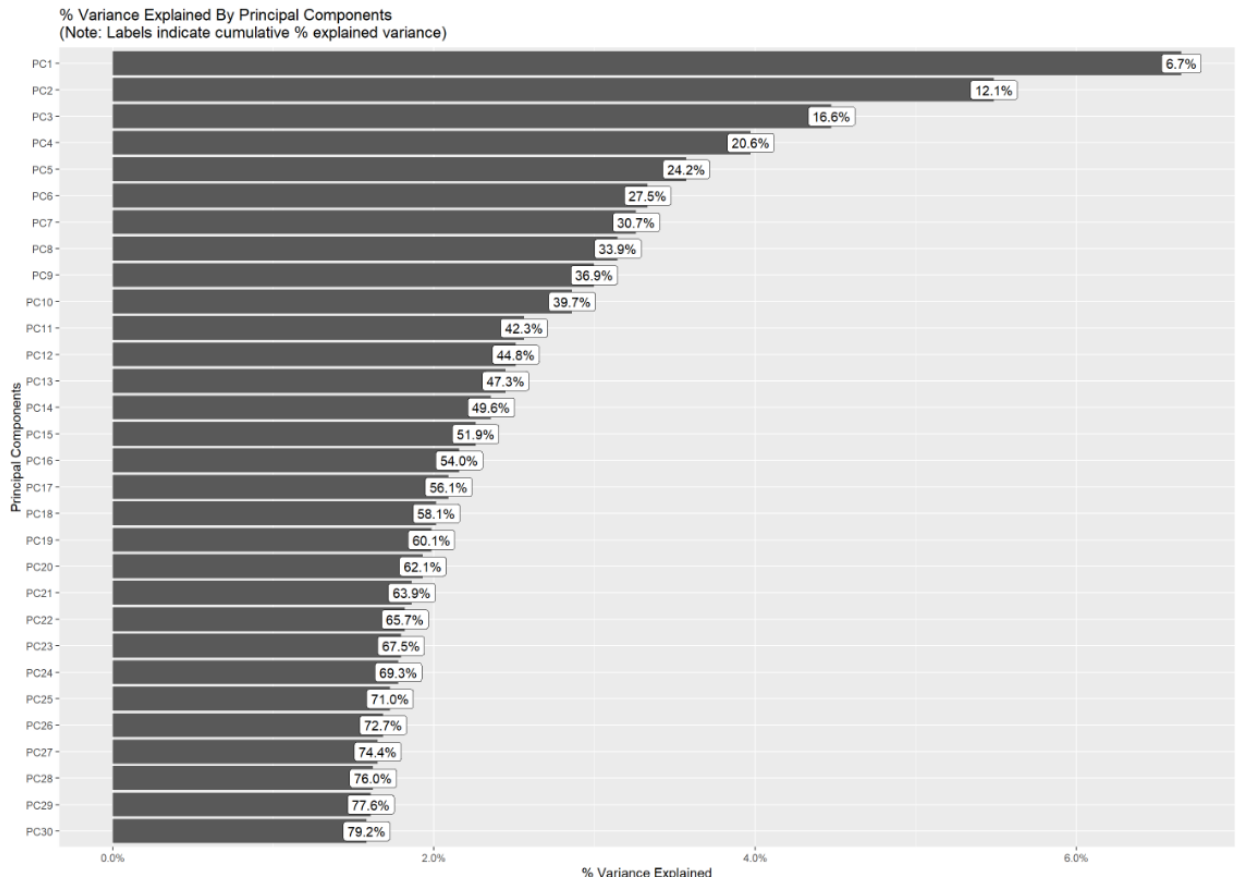

Oprócz tego postanowiliśmy sami przyjrzeć się wybranym cechom.

Okazało się między innymi, że stereotypy można wyrzucić do kosza - mężczyźni o wiele częściej biorą kredyt ze względu na potrzebę funduszy na gospodarstwo domowe i nie widać znaczącej przewagi w stosunku do kobiet jeśli idzie o chęć postawienia pieniędzy na auto.

Bez zaskoczeń o wiele częściej na dom stawiają mężczyźni po ślubie niż ci samotni czy rozwodnicy. Co ciekawe ci sami ani razu nie wzięli pożyczki na wyposażenie / meble [przynajmniej na te 1000 osobników], zaś rozwodnicy i separatyści... przeciwnie do pozostałych grup nie myślą tu wręcz wcale o dodatkowej mamonie na biznes.

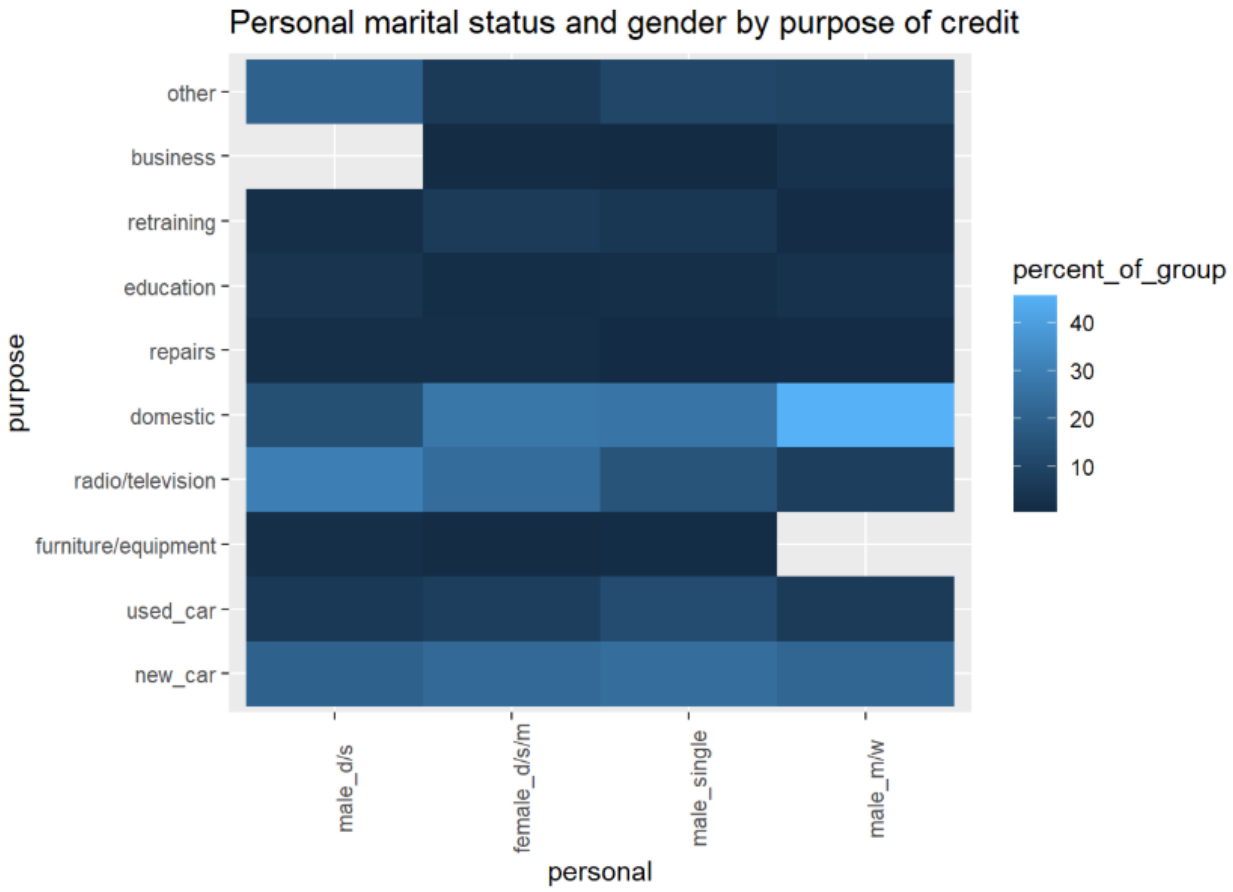

Wychodzi również na to, że generalnie większym zaufaniem firma daży osoby starsze:

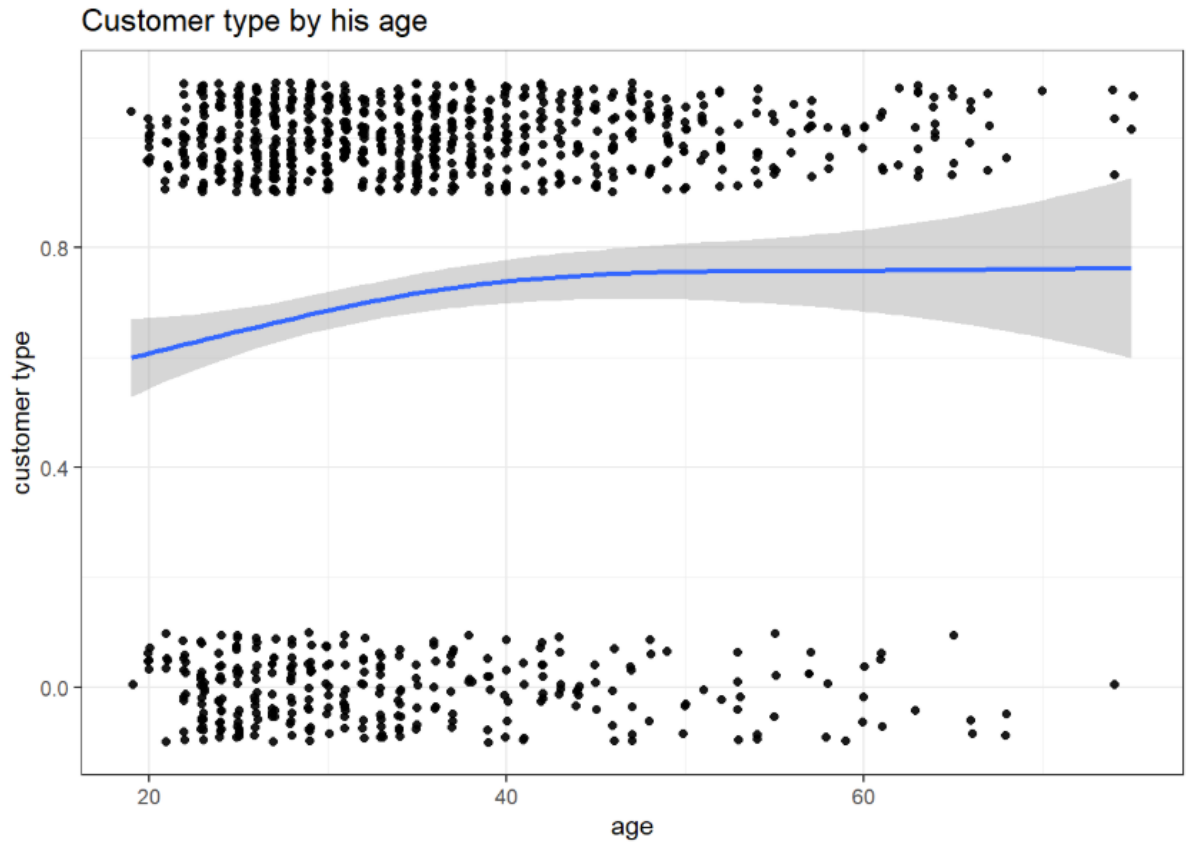

Wyciągnęliśmy także wnioski na podstawie płci, wieku i stanu cywilnego.

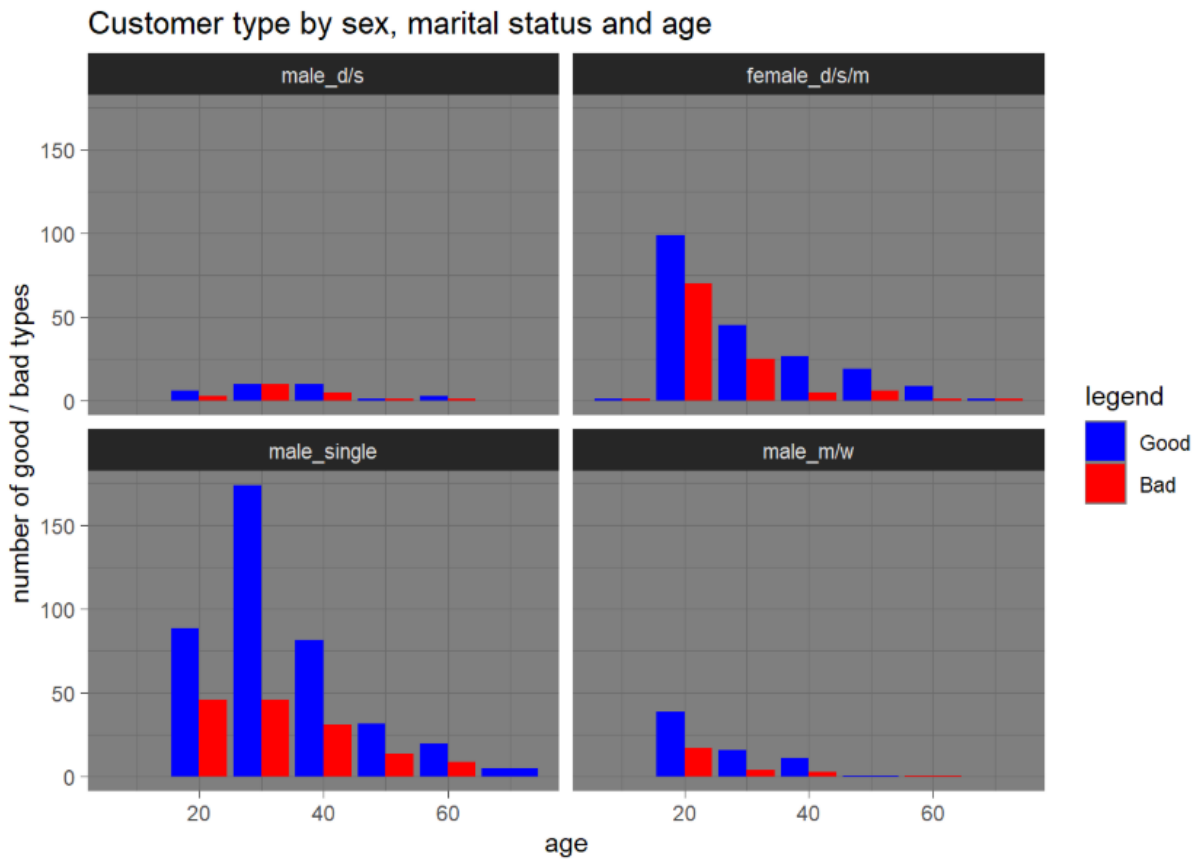

Dane mówią, że:

1. Najmniej ufamy rozwiedzionym facetom - zwłaszcza tym po 30, im zwykle nie dajemy.
2. Najbezpieczniejsi za to są też faceci po 30... ale single.
3. Żonaci to też dobre ziomki.
4. Kobiety są gorsze od mężczyzn, ale tylko przed 40. Potem raczej spokój, za wyjątkiem 70-tki psującej obraz.

Jak można się było spodziewać, pożyczka chętniej jest także udzielana na krótszy okres czasu.

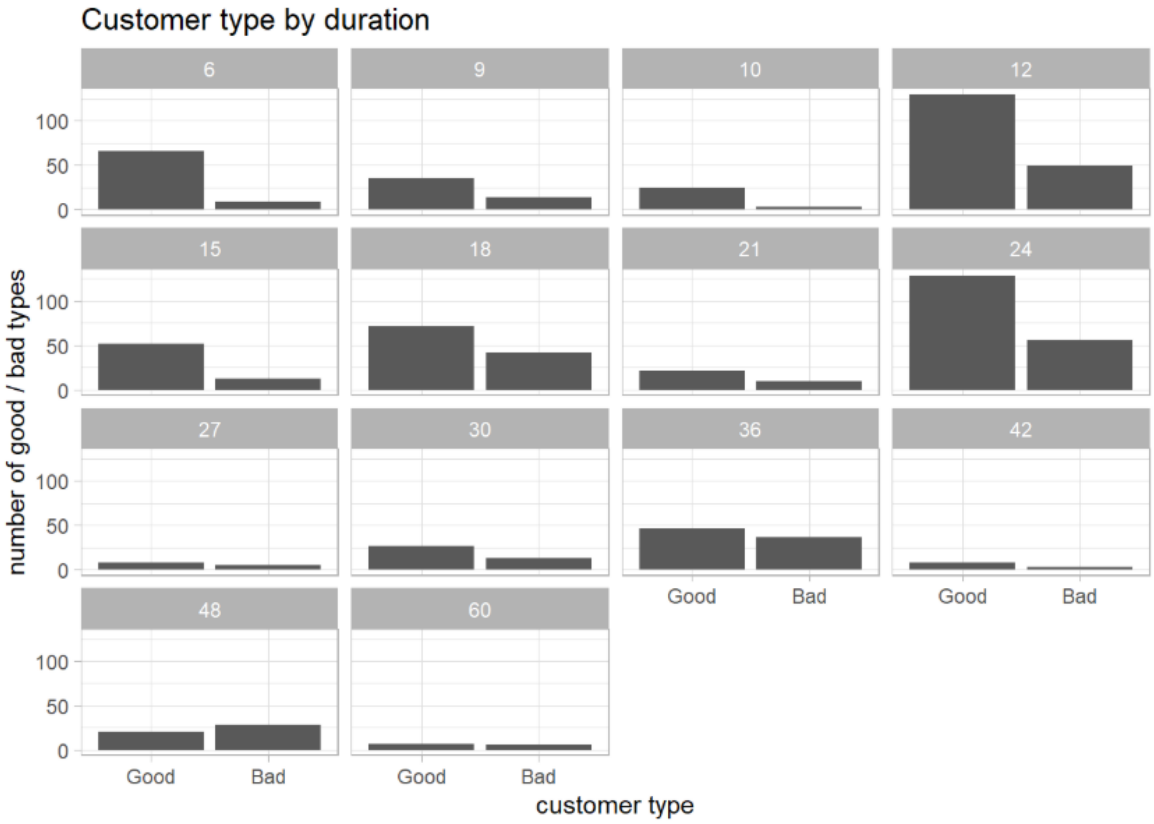
Customer type by duration
6
9
10
12
15
18
21
24
27
30
36
42
48
60
100
50
0
number of good / bad types
Good
Bad
customer type

4. Kodowanie

W ramach drugiego kamienia milowego dokonaliśmy szczegółowej analizy pod względem sensownego encodingu i **każdej kolumnie przyjrzeliśmy się pod lupą**.

Spośród 21 kolumn, aż 14 okazało się być tekstowymi.

Do czynienia mieliśmy z problemami:

1. Prostych zmiennych binarnych
2. Kolumn nominalnych
3. Cech uporządkowanych

3.3.1. Zarobki w skali 0-4

... oczywiście jednoznacznie mozna uporządkować.

Do jednej kupy został wsadzony brak zarobków i brak informacji na ich temat - rozsądnie będzie obu przydzielić 0, gdyż można się spodziewać, że tak istotna informacja raczej nie byłoby zatajana przez osobę ubiegającą się o pożyczkę i realistycznie jest ona raczej w grupie *low* (przynajmniej według mnie - przypowiedź Kuba).

Wobec tego kolejne numery będą miały takie dopasowanie:

- not_have/unknown –> 0
- low –> 1
- normal –> 2
- high –> 3
- very_high –> 4

```
num_data$savings <- as.numeric(data$savings)
num_data$savings[num_data$savings == 5] <- 0 # not_have/unknown
```

3.3.2. Staż pracy w przybliżonych liczbach

Kolumna *present_employment* daje nam ładne pogrupowanie długości pracy w formie grup *unemployed*, *less_than_year*, *1-3_years*, *4-6_years* i *more*. Zamienimy dane kategoryczne na liczbę oznaczającą oczekiwany staż pracy jak niżej:

- unemployed –> 0
- less_than_year –> 1
- 1-3_years –> 2
- 4-6_yeras –> 5
- more –> 7

```
num_data$present_employment <- if_else(data$present_employment %in% c("unemployed"), 0, if_else(data$present_employment %in% c("less_than_year"), 1,if_else(data$present_employment %in% c("1-3_years"), 2,if_else(data$present_employment %in% c("4-6_yeras"), 5,7))))
```

4. Zmiennych mieszanych - zawierających w sobie po parę ciekawych informacji

3.4. Zmienne “mieszane”

3.4.1. *personal* czyli pleć i stan cywilny na raz

Tu zrobimy dwie kolumny numeryczne - pierwszą binarną *is_woman* naturalnie odpowiadającą za płeć, dodatkową za pytanie o bycie singlem. W tym wypadku tracimy małą informację w stosunku do oryginalnego zbioru danych o odróżnieniu singli i rozwodników, ale jest to bardzo mała grupa, a podział na płeć powinien przynieść bardziej porządany efekt.

```
num_data$is_woman <- if_else(data$personal == "female_d/s/m", 1, 0)
num_data$is_single <- if_else(data$personal == "male_single", 1, 0) # nie ma kobiet singli
```

Końcowy efekt wyszedł encodingu wyszedł następujący:

duration	credit_amount	installment_rate	present_residence	age	existing_credits	dependents	has_telephone	is_foreign_worker	is_good_customer_type	I
48	3914	4	2	38	1	1	0	1	0	
12	1922	4	2	37	1	1	0	1	0	
18	1345	4	3	26	1	1	0	1	0	
12	983	1	4	19	1	1	0	1	1	
21	3652	2	3	27	2	1	0	1	1	
18	1453	3	1	26	1	1	0	1	1	
24	3069	4	4	30	1	1	0	1	1	
8	1164	3	4	51	2	2	1	1	1	
18	2462	2	2	22	1	1	0	1	0	
36	7980	4	4	27	2	1	1	1	0	
18	2169	4	2	28	1	1	1	1	0	
48	7629	4	2	46	2	2	0	1	1	
48	6416	4	3	59	1	1	0	1	0	

Tutaj kolory odpowiadające miarom:

- żółty - *accuracy*
- niebieski - *precision*
- zielony - *recall*
- czerwony - *f1*

5. Poszukiwanie najlepszego modelu - dyskusja

W celu wybrania tego jednego właściwego modelu, wpierw postanowiliśmy podzielić się popularnymi znanymi już przez nas metodami i indywidualne zajęcie się nimi. Stworzyliśmy następujące modele:

1. Drzewa
2. K najbliższych sąsiadów
3. Regresja Liniowa
4. Regresja Logistyczna
5. Naiwny klasyfikator bayesowski

Cała praca nad tworzeniem, badaniem i rozwijaniem modeli została opisana w osobnych raportach. Kojejno: *KM3Drzewa.Rmd*, *KM3Knn.Rmd*, *KM3RegresjaLiniowa.Rmd*, *KM3RegresjaLogistyczna.Rmd* i *KM3NaiwnyBayes.Rmd*.

5.1. Drzewo klasyfikacyjny i las losowy

Ku porównaniu efektów modeli postanowiliśmy porównywać cztery chyba najbardziej podstawowe w tej kwestii, ale i przy tym dające ogrom informacji miary: **accuracy**, **precision**, **recall** i **f1**.

2. Miary oceny klasyfikatora

W ocenie kolejnych modeli posłużę się czterema najbardziej klasycznymi miarami:

- *accuracy* - $\frac{TP+TN}{TP+FP+FN+TN}$
- *precision* - $\frac{TP}{TP+FP}$
- *recall* - $\frac{TP}{TP+FN}$
- *f1* - $2 * \frac{Recall*Precision}{Recall+Precision}$

```
confusion_matrix_values <- function(confusion_matrix){
  TP <- confusion_matrix[2,2]
  TN <- confusion_matrix[1,1]
  FP <- confusion_matrix[1,2]
  FN <- confusion_matrix[2,1]
  return (c(TP, TN, FP, FN))
}

accuracy <- function(confusion_matrix){
  conf_matrix <- confusion_matrix_values(confusion_matrix)
  return((conf_matrix[1] + conf_matrix[2]) / (conf_matrix[1] + conf_matrix[2] + conf_matrix[3] + conf_matrix[4]))
}

precision <- function(confusion_matrix){
  conf_matrix <- confusion_matrix_values(confusion_matrix)
  return(conf_matrix[1]/ (conf_matrix[1] + conf_matrix[3]))
}

recall <- function(confusion_matrix){
  conf_matrix <- confusion_matrix_values(confusion_matrix)
  return(conf_matrix[1] / (conf_matrix[1] + conf_matrix[4]))
}

f1 <- function(confusion_matrix){
  conf_matrix <- confusion_matrix_values(confusion_matrix)
  rec <- recall(confusion_matrix)
  prec <- precision(confusion_matrix)
  return(2 * (rec * prec) / (rec + prec))
}
```

Uruchomienie algorytmu z pakietu *rpart* dało mało satysfakcjonujący wynik w myśli o logice biznesowej.

```
rpart.plot(primitive_model, type = 3, box.palette = c("red", "green"), fallen.leaves = TRUE)
```

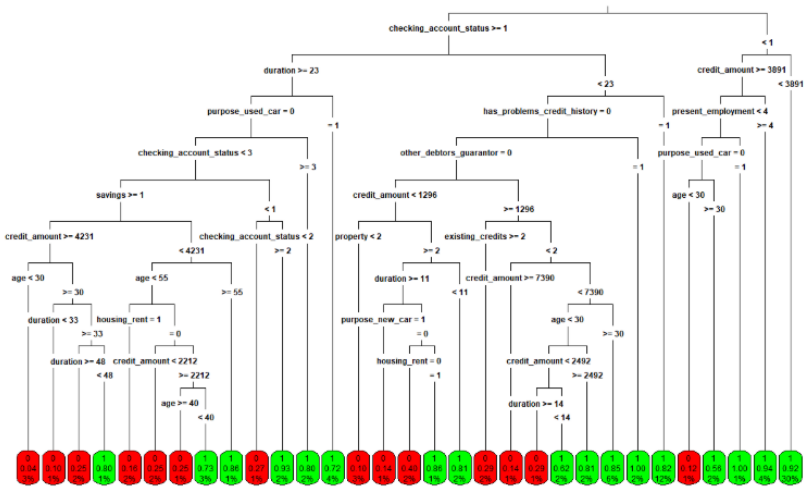

W celu znalezienia najlepszych hiperparametrów, porównywaliśmy między innymi miary dla kolejnych maksymalnie narzuconych głębokości drzewa.

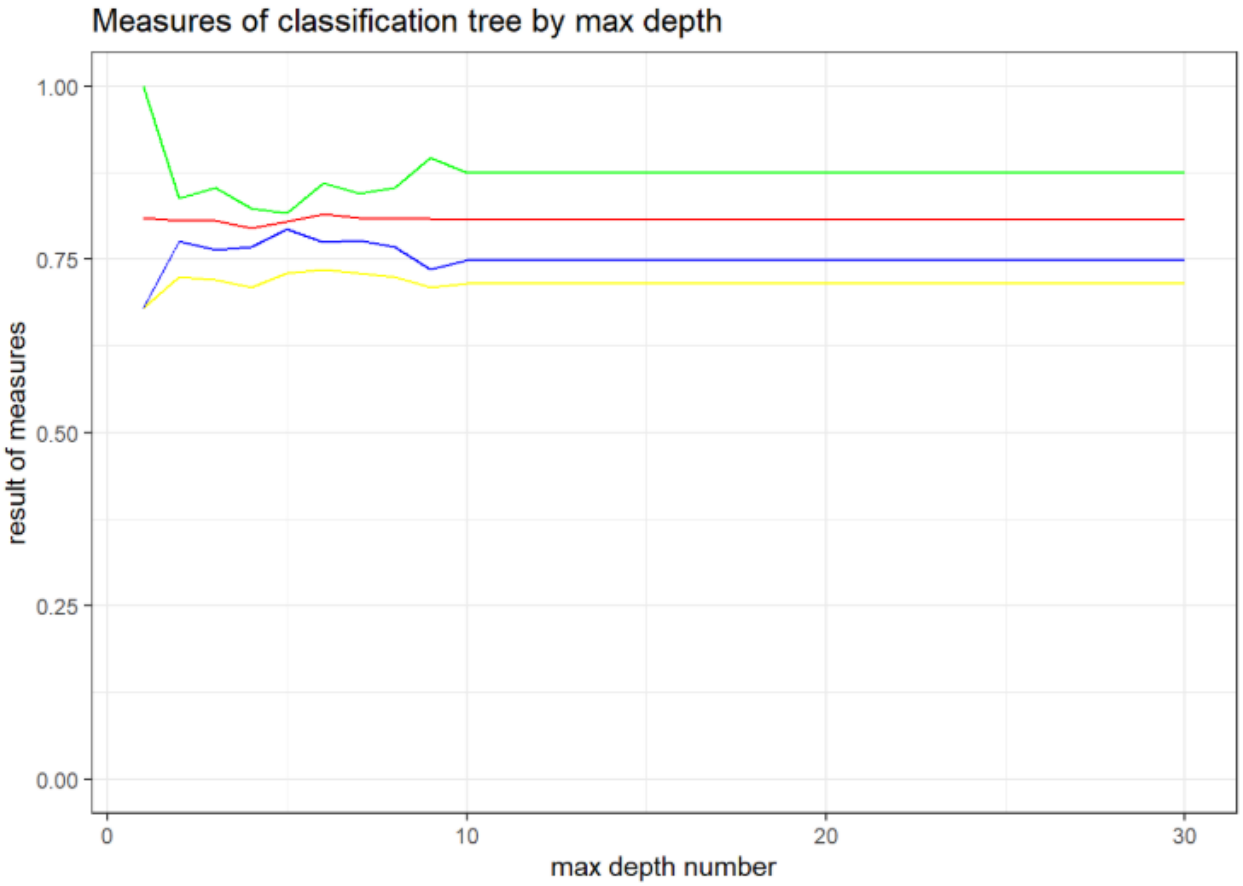

Tutaj:

- żółty - *accuracy*
- niebieski - *precision*
- zielony - *recall*
- czerwony - *f1*

Biorąc pod uwagę ideę naszego problemu, zdecydowaliśmy się na to z głębokością 6.

Prezentuje się ono tak:

Zajęliśmy się także **lasami losowymi** i koniec końców porównaliśmy otrzymane miary.

W efekcie otrzymaliśmy taką oto tabelkę:

```
##           model accuracy precision    recall        f1
## 1     primitive    0.715 0.7484277 0.8750000 0.8067797
## 2  max depth: 6    0.735 0.7748344 0.8602941 0.8153310
## 3 random forest    0.720 0.7325581 0.9264706 0.8181818
```

Ze względu na koncepcję naszego zadania, stwierdziliśmy, że **sumarycznie najlepiej wypada drzewo losowe o głębokości 6**.

5.2. k najbliższych sąsiadów

Jest to algorytm polegający na "porównaniu" badanej próbki z wartościami które mamy w bazie i wywnioskowanie na podstawie k rekordów z bazy jak zklasyfikować próbkę. Do tego potrebujemy specjalnie unormowanych danych.

```
#normaliacion to ~(0,1)
for( coli in 1:dim(x_train)[2]){
  #x and y have o be noemalized in the same way
  c_min <- min( c(x_train[,coli], x_test[,coli]))
  c_max <- max( c(x_train[,coli], x_test[,coli]))

  x_train[,coli] <- (x_train[,coli] - c_min) / (c_max - c_min)
  x_test[,coli] <- (x_test[,coli] - c_min) / (c_max - c_min)
}
```

Używając funkcji knn() z pakietu class możemy stworzyć nasz model. Pozostaje nam dopasowanie parametru k tak aby nasz model był jak najbardziej optymalny. Do tego posłużymy się zwykłą metryką celności (%

poprawnych klasyfikacji)

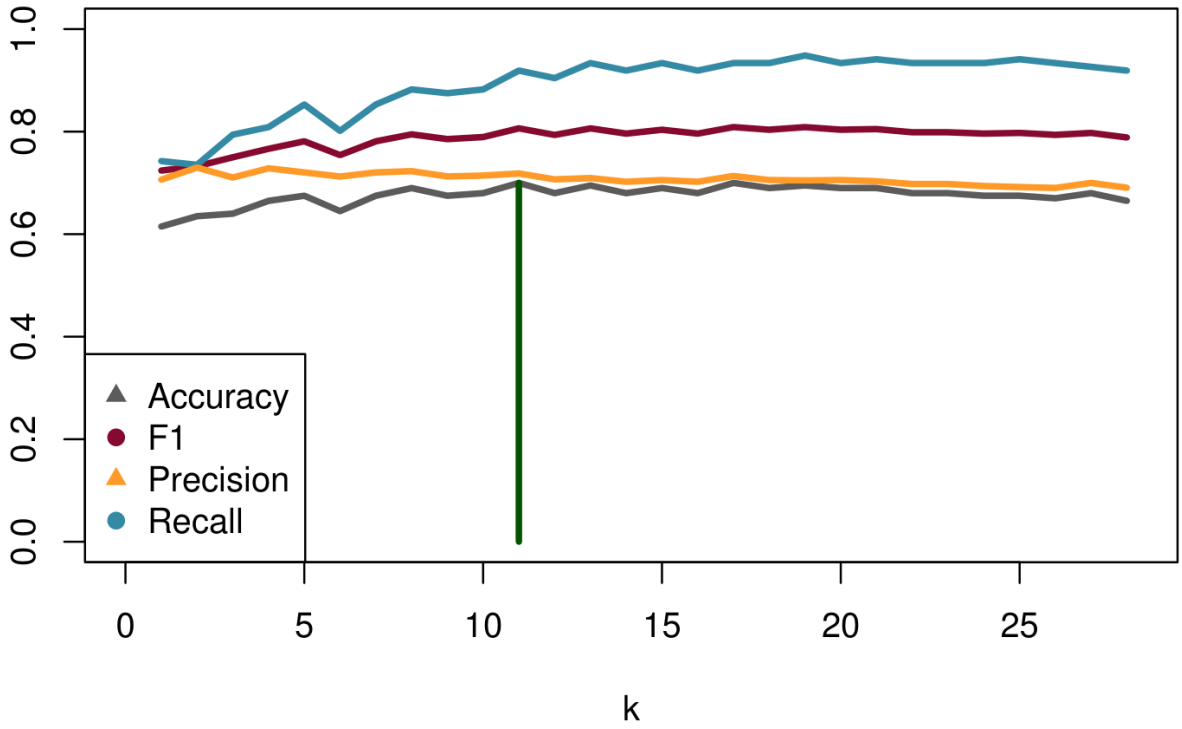

Otrzymujemy parametr $k = 11$.

	0	1
0	12	52
1	9	127

Tak wygląda nasza tabela. Finalnie model uzyskuje 69.5% celności.

5.3. Regresja liniowa

Regresja liniowa polega na stworzeniu modelu na podstawie zależności liniowych pomiędzy zmiennymi.

```
train <- cbind( x_train, y_train) # Łączenie naszych ramek danych
train_lm <- lm( x~., train)
pred_train <- predict(  train_lm, x_test)
```

Po stworzeniu modelu należy znaleść odpowiedni punkt odcieńcia który przy naszych zmiennych binarnych wskaże kiedy określone prawdopodobieństwo oznacza przynależność do konkretnej grupy.

Nasz model regresji liniowej osiąga dla podziału 50%/50% osiągając przy tym 73.5% celności.

5. 4. Regresja logistyczna

Regresja Logistyczna polega na analogicznym moeleowaniu jak Regresja Liniowa jednakżę zamiast używać zależności liniowych nasz model będzie obliczał prawdopodobieństwa w zależności o krzywą logistyczną. Tak wygląda krzywa logistyczna:

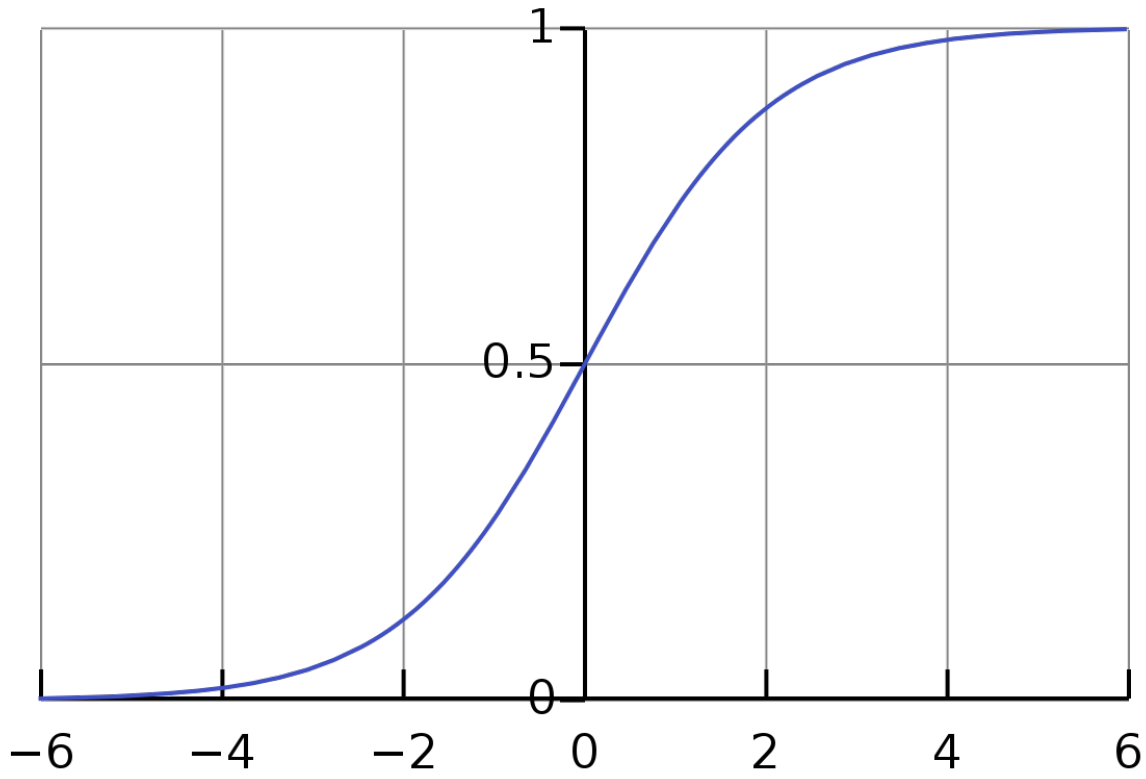

Sam model można modyfikować tylko za pomocą wybierania konkretnych zmiennych na których będziemy opierać nasz model. Bardzo pomocna jest funkcja summary() która pokazuje z jakich zmiennych stworzony jest nasz model i jaki wpływ na zachowanie ma każda zmienna.

```r
summary(glm.fit)
```

```
##
## Call:
## glm(formula = is_good_customer_type ~ duration + age + existing_credits +
##     dependents + has_telephone + is_foreign_worker + has_problems_credit_history +
##     purpose_domestic + purpose_retraining + purpose_radio_television +
##     purpose_new_car + purpose_used_car + purpose_business + purpose_repairs +
##     purpose_education + purpose_furniture_equipment + other_debtors_guarantor +
##     other_debtors_co_applicant + other_installment_plans_bank +
##     other_installment_plans_stores + housing_rent + housing_own +
##     job_skilled_employee + job_unskilled_resident + job_highly_qualified_employee +
##     savings + present_employment + property + checking_account_status +
##     is_woman + is_single, family = binomial, data = Reg_train)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.4722  -0.8899   0.4654   0.7781   2.3977
##
## Coefficients:
##                                 Estimate Std. Error z value Pr(>|z|)
## (Intercept)                     3.384690   1.241297   2.727  0.00640 **
## duration                       -0.042163   0.007819  -5.392 6.97e-08 ***
## age                             0.012578   0.009399   1.338  0.18084
## existing_credits               -0.394848   0.188578  -2.094  0.03628 *
## dependents                     -0.486423   0.265525  -1.832  0.06696 .
## has_telephone                   0.456194   0.207464   2.199  0.02788 *
## is_foreign_worker              -1.482214   0.768042  -1.930  0.05362 .
## has_problems_credit_history     0.782436   0.226453   3.455  0.00055 ***
## purpose_domestic                0.302664   0.334697   0.904  0.36584
## purpose_retraining             -0.772425   0.448215  -1.723  0.08483 .
## purpose_radio_television       -0.042468   0.352021  -0.121  0.90398
## purpose_new_car                -0.671123   0.335964  -1.998  0.04576 *
## purpose_used_car                1.109216   0.451582   2.456  0.01404 *
## purpose_business                1.009181   1.142224   0.884  0.37695
## purpose_repairs                -0.334217   0.843957  -0.396  0.69210
## purpose_education              -0.543683   0.601829  -0.903  0.36632
## purpose_furniture_equipment     0.439982   0.828232   0.531  0.59526
## other_debtors_guarantor         0.634619   0.451470   1.406  0.15982
## other_debtors_co_applicant     -0.811476   0.444269  -1.827  0.06777 .
## other_installment_plans_bank   -0.367892   0.248429  -1.481  0.13864
## other_installment_plans_stores -0.702364   0.387586  -1.812  0.06996 .
## housing_rent                   -0.143903   0.389959  -0.369  0.71211
## housing_own                     0.270075   0.336478   0.803  0.42218
```

Model zachowuje się podobnie niezależnie od ilości zmiennych. Metryki oczywiście zmieniają swoje wartości w zależności od modelu ale nie są to duże zmiany. Model osiąga średnie wartości dla wszystkich przetestowanych wartości. Sama funkcja podumuwująca jest bardzo przydatna ponieważ daje nam ciekawy sposób na analize zależności między danymi. Podsumuwując ten model osiąga niezbyt imponujące wyniki widoczne poniżej:

accuracy	precision	recall	f1
0.69	0.7015707	0.9640288	0.8121212

5. 5. Naiwny klasyfikator bayesowski

Jest to rodzina klasyfikatorów używająca do pracy twierdzenia bayesa.

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}$$

Aby nasz model mógł wykorzystać dane musimy je odpowiednio przetworzyć. Z powodu swojej natury nie przyjmuje on wartości ciągłych(Warunkowość wyszła by dla każdej ciągłej wartości osobno co jest sprzeczne z założeniem modelu). Dlatego zmienne ciągłe "kubełkuje" się do grup z odpowiednimi przedziałami.

```
#podział ciągłych danych.
data$age <- cut( data$age, breaks = seq( 10, 80, by = 10))
data$duration <- cut( data$duration, breaks = c(0,12,24,36,48,60,72))
```

Nasz model tworzym z pakietu "e1071". Po wytrenowaniu go można pokazać krzywą ROC

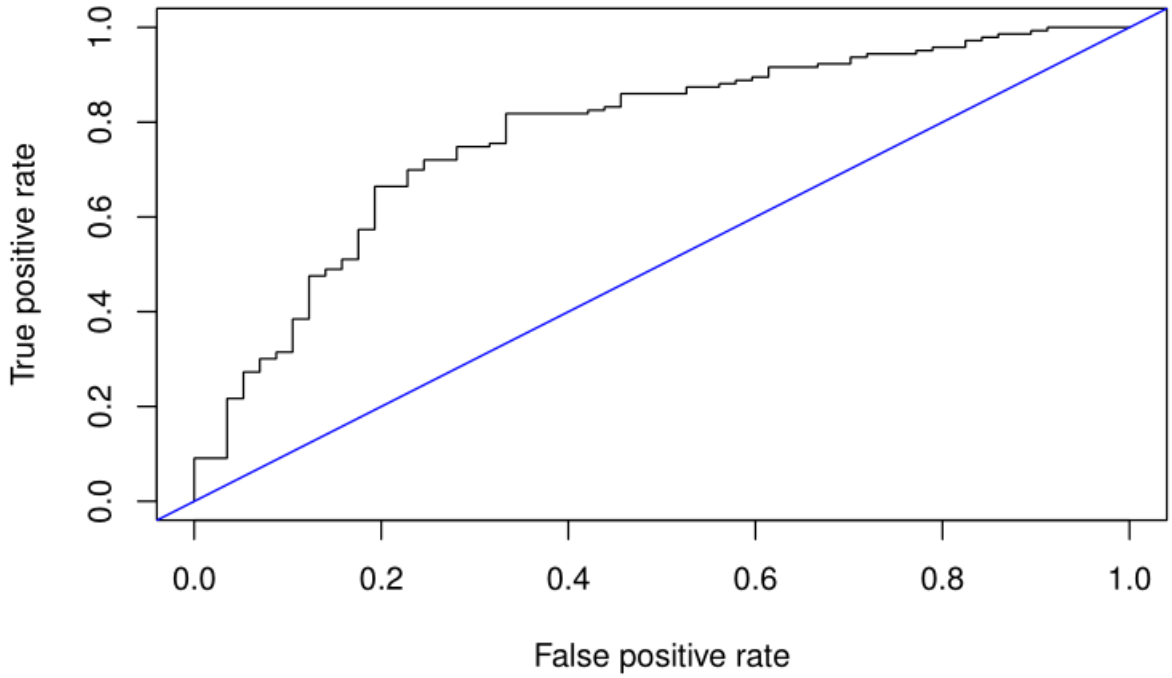

Tutaj również dopasowaliśmy punkt odcięcia. Podsumuwując:

Dla punktu odcięcia 0.6 otrzymujemy następujące wyniki:

Celność : 0.775

F1 : 0.628099173553719

Recall : 0.666666666666667

Precision : 0.59375

6. Wybór najlepszego algorytmu uczenia maszynowego i implementacja

Przetestowaliśmy 5 algorytmów. Najlepszym z nich okazał się klasyfikator bayesowski. Osiąga on znacznie lepsze wyniki niż reszta naszych klasyfikatoróW.

Bayes : 77.5 % Regresja Liniowa : 73.5%

7. Zakończenie

To by było na tyle.

Mamy nadzieję, że się podobało; ja myślę, że fajna robota (dopowiedź: Kuba).

```
sessionInfo()
```

```
## R version 3.6.1 (2019-07-05)
## Platform: x86_64-w64-mingw32/x64 (64-bit)
## Running under: Windows 10 x64 (build 18362)
##
## Matrix products: default
##
## locale:
## [1] LC_COLLATE=English_United States.1252
## [2] LC_CTYPE=English_United States.1252
## [3] LC_MONETARY=English_United States.1252
## [4] LC_NUMERIC=C
## [5] LC_TIME=English_United States.1252
##
## attached base packages:
## [1] stats     graphics  grDevices utils     datasets  methods   base
##
## loaded via a namespace (and not attached):
##  [1] compiler_3.6.1  magrittr_1.5    tools_3.6.1     htmltools_0.4.0
##  [5] yaml_2.2.1      Rcpp_1.0.3      stringi_1.4.6   rmarkdown_2.1
##  [9] knitr_1.28      stringr_1.4.0   xfun_0.12       digest_0.6.25
## [13] rlang_0.4.5     evaluate_0.14
```